

Ландшафт функции потерь для архитектуры трансформер

Егор Петров

МФТИ


Руководитель: Андрей Грабовой, к.ф-м.н.

2026

Проблема: неполная характеристика кривизны

Почему матрица Гессе важна

- ▶ Геометрия второго порядка определяет сходимость, обобщение, масштабирование
- ▶ Поведение оптимизатора, критического размера батча, эволюции ландшафта функции потерь



(a) Сходимость ландшафта лосса (b) Анализ трансформера на основе Гессеана

Цель: Изучить ландшафт функции потерь для трансформера

Основные результаты

1. Матричное исчисление LayerNorm (теоремы 2-3)

Первые явные якобиан и матрица Гессе для LayerNorm в нотации vec_r

- ▶ Декомпозиция: $\text{LayerNorm}(\mathbf{X}) = \mathbf{P}(\mathbf{X})\mathbf{M}(\mathbf{X})$
- ▶ Новые леммы матричного исчисления для $\text{diag}^{-1}(\cdot)$, $\mathbf{A}^{\circ 1/2}$

2. Полная матрица Гессе блока трансформера (теорема 5)

Полная характеристика второго порядка через разложение Гаусса-Ньютона:

$$\mathbf{H}_{\text{tr}}^{(i,j)} = (\mathbf{J}_Z \otimes \mathbf{I})\xi_{ij} + (\mathbf{I} \otimes \mathbf{B}_i^\top)\mathbf{H}_Z\mathbf{B}_j$$

3. Границы спектральной нормы и сходимость (теоремы 3.4, 3.6)

$$\|\mathbf{H}^{(k)}\|_2 \leq M \Rightarrow |\mathcal{L}_{k+1} - \mathcal{L}_k| \leq \mathcal{O}(1/k)$$

Справочник по обозначениям

Данные и размерности

$\mathbf{X}$	Эмбединги $\in \mathbb{R}^{L \times d_V}$
L	Длина последовательности
d_V	Размерность value
d_K	Размерность key/query
d_{ff}	Размерность скрытого слоя
k	Размер датасета

Параметры

$\mathbf{w}$	Все параметры
$\mathbf{w}^*$	Лок. минимум
$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$	Веса attention
$\mathbf{W}_1, \mathbf{W}_2$	Веса FFN

Функция потерь и оптимизация

$\mathcal{L}_k(\mathbf{w})$	Функция потерь
$\mathbf{H}^{(k)}(\mathbf{w})$	Матрица Гессе
M	Граница нормы

Компоненты attention

$\mathbf{F}(\mathbf{X})$	Выход self-attention
$\mathbf{A}(\mathbf{X})$	Матрица softmax
$\mathbf{G}_k$	$\frac{\partial \mathbf{F}}{\partial \mathbf{W}_k}$ (якобиан)
$\Phi_{k\ell}$	$\frac{\partial \mathbf{G}_k}{\partial \mathbf{W}_\ell}$ (кривизна)

Выходы трансформера

$\mathbf{Y}$	После 1 LayerNorm+residual
$\mathbf{S}$	$\text{FFN}(\mathbf{Y}) + \mathbf{Y}$
$\mathbf{Z}$	после 2 LN

Якобианы и Гессианы

$\mathbf{J}_Z, \mathbf{H}_Z$	Якобиан/Гессиан LN
$\mathbf{B}_i$	$\frac{\partial \mathbf{S}}{\partial \mathbf{W}_i}$ (1-й порядок)
ξ_{ij}	$\frac{\partial \mathbf{B}_i}{\partial \mathbf{W}_j}$ (2-й порядок)

Технические обозначения

$\text{vec}_r(\cdot)$	Векторизация
$\ \cdot\ _2$	Спектральная норма
$\otimes$	Произведение Кронекера

Обозначения и формализм

Построчная векторизация (по работе Ormaniec et al.)

Для $\mathbf{F} : \mathbb{R}^{p \times q} \rightarrow \mathbb{R}^{n \times d}$,

$$\frac{\partial \mathbf{F}}{\partial \mathbf{W}_i} := \frac{\partial \text{vec}_r(\mathbf{F})}{\partial \text{vec}_r(\mathbf{W}_i)^\top} \in \mathbb{R}^{nd \times p_i q_i}, \quad \frac{\partial^2 \mathbf{F}}{\partial \mathbf{W}_i \partial \mathbf{W}_j} \in \mathbb{R}^{(nd \cdot p_i q_i) \times p_j q_j}$$

Блок трансформера

$$\begin{aligned} \mathbf{Y} &= \text{LayerNorm}(\mathbf{X} + \mathbf{F}(\mathbf{X})), \quad \mathbf{F}(\mathbf{X}) = \mathbf{A}(\mathbf{X})\mathbf{X}\mathbf{W}_V \\ \mathbf{Z} &= \text{LayerNorm}(\mathbf{Y} + \text{FFN}(\mathbf{Y})), \quad \text{FFN} = \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2 \end{aligned}$$

Разложение Гаусса-Ньютона

$$\frac{\partial^2 (\mathcal{L} \circ f)}{\partial \mathbf{W}_i \partial \mathbf{W}_j} = \underbrace{\frac{\partial f}{\partial \mathbf{W}_i}^\top \frac{\partial^2 \mathcal{L}}{\partial f^2} \frac{\partial f}{\partial \mathbf{W}_j}}_{\text{Hessian of } \mathcal{L} \text{ at } f} + \underbrace{\left(\frac{\partial \mathcal{L}}{\partial f} \otimes \mathbf{I} \right) \frac{\partial^2 f}{\partial \mathbf{W}_i \partial \mathbf{W}_j}}_{\text{Cross terms}}$$

Якобиан LayerNorm

Проблема

LayerNorm является *нелинейным* (построчная нормализация):

$$\text{LayerNorm}(\mathbf{X})_{i,j} = \gamma_j \frac{\mathbf{X}_{i,j} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} + \beta_j$$

Декомпозиция по правилу произведения

Перепишем как $\text{LayerNorm}(\mathbf{X}) = \mathbf{P}(\mathbf{X})\mathbf{M}(\mathbf{X})$, где:

- ▶ $\mathbf{M}(\mathbf{X}) = \mathbf{X} - \frac{1}{d_V} \mathbf{X} \mathbf{1} \mathbf{1}^\top$ (центрирование, линейно)
- ▶ $\mathbf{P}(\mathbf{X}) = \text{diag}^{-1}(\sigma(\mathbf{X}))$ (масштабирование, нелинейно)

Теорема 2 (якобиан LayerNorm)

$$\frac{\partial \text{LayerNorm}}{\partial \mathbf{X}} = (\mathbf{P} \otimes \mathbf{I}) \mathbf{G} + (\mathbf{I} \otimes \mathbf{M}^\top) \frac{\partial \mathbf{P}}{\partial \mathbf{X}}$$

где $\mathbf{G} = \mathbf{I} - \frac{1}{d_V} (\mathbf{I} \otimes \mathbf{1} \mathbf{1}^\top)$ и $\frac{\partial \mathbf{P}}{\partial \mathbf{X}}$ требует новых лемм

Матрица Гессе LayerNorm

Технические препятствия

1. $\frac{\partial \mathbf{P}}{\partial \mathbf{X}}$ содержит $\text{diag}^{-1}(\sigma(\mathbf{X}))$ — нужны производные обратной матрицы и корня Адамара
2. Цепное правило через $\sigma(\mathbf{X}) = \frac{1}{\sqrt{d_V}} (\mathbf{M}^{\circ 2} \mathbf{1})^{\circ 1/2}$

Леммы матричного исчисления

- ▶ Утверждение 4: $\frac{\partial \mathbf{D}^{-1}}{\partial \mathbf{D}} = -\mathbf{D}^{-1} \otimes \mathbf{D}^{-\top}$
- ▶ Утверждение 6: $\frac{\partial \mathbf{A}^{\circ 2}}{\partial \mathbf{A}} = 2 \text{diag}(\text{vec}_r(\mathbf{A}))$
- ▶ Утверждение 7: $\frac{\partial \mathbf{A}^{\circ 1/2}}{\partial \mathbf{A}} = \frac{1}{2} \text{diag}^{-1}(\text{vec}_r^{1/2}(\mathbf{A}))$

Теорема 3 (матрица Гессе LayerNorm)

$$\begin{aligned} \frac{\partial^2 \text{LayerNorm}}{\partial \mathbf{X}^2} &= \left(\mathbf{I}_{L d_V} \otimes \mathbf{G}^\top \right) \frac{\partial (\mathbf{P}(\mathbf{X}) \otimes \mathbf{I}_{d_V})}{\partial \mathbf{X}} + \left((\mathbf{I}_L \otimes \mathbf{M}^\top) \otimes \mathbf{I}_{L d_V} \right) \frac{\partial^2 \mathbf{P}}{\partial \mathbf{X}^2} \\ &\quad + \left(\mathbf{I}_{L d_V} \otimes \left(\frac{\partial \mathbf{P}}{\partial \mathbf{X}} \right)^\top \right) \frac{\partial (\mathbf{I}_L \otimes \mathbf{M}^\top)}{\partial \mathbf{X}}. \end{aligned}$$

Feed-Forward Network: вклад в кривизну

FFN-блок

$$\text{FFN}(\mathbf{Y}) = \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2, \quad \sigma = \text{ReLU}.$$

Якобианы FFN (Утверждение 10)

$$\frac{\partial \mathbf{V}}{\partial \mathbf{W}_2} = \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_{d_V},$$

$$\frac{\partial \mathbf{V}}{\partial \mathbf{W}_1} = (\mathbf{I}_L \otimes \mathbf{W}_2^\top) \mathbf{D}_\sigma(\mathbf{Y} \otimes \mathbf{I}_{d_{ff}}).$$

$$\mathbf{D}_\sigma = \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{Y}\mathbf{W}_1 > 0\}})).$$

Почему FFN важен для Гессиана

- ▶ ReLU имеет нулевой Гессиан почти всюду.
- ▶ Но смешанные производные по $\mathbf{W}_1$ и $\mathbf{W}_2$ не исчезают.

Полная матрица Гессе блока трансформера

Теорема 5 (матрица Гессе блока трансформера)

Для выхода $\mathbf{Z} = \text{LayerNorm}(\mathbf{S})$, $\mathbf{S} = \text{ReLU}(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2 + \mathbf{Y}$:



$$\mathbf{H}_{\text{tr}}^{(i,j)} = (\mathbf{J}_Z \otimes \mathbf{I}_{n_i})\xi_{ij} + (\mathbf{I} \otimes \mathbf{B}_i^\top)\mathbf{H}_Z\mathbf{B}_j$$

где:

- ▶ $\mathbf{J}_Z = \frac{\partial \text{LayerNorm}(\mathbf{S})}{\partial \mathbf{S}}$ (теорема 2)
- ▶ $\mathbf{H}_Z = \frac{\partial^2 \text{LayerNorm}(\mathbf{S})}{\partial \mathbf{S}^2}$ (теорема 3)
- ▶ $\mathbf{B}_i = \frac{\partial \mathbf{S}}{\partial \mathbf{W}_i}$ (утверждение 10)
- ▶ $\xi_{ij} = \frac{\partial \mathbf{B}_i}{\partial \mathbf{W}_j}$ (взаимодействия второго порядка)

Ключевая идея: почти всюду симметрия $\mathbf{H}_{\text{tr}}^{(i,j)} = \mathbf{H}_{\text{tr}}^{(j,i)}$, поскольку матрица Гессе ReLU равна нулю п.в. (лемма A.9), остальные отображения мультилинейны по параметрам

Экспериментальная валидация




LayerNorm Jacobian

FFN Jacobian


Таблица: Empirical validation: theoretical formulas vs. autograd (FP32 precision). Every quantity achieves machine-level agreement.

Component	Rel. Error
FFN Jacobian $\partial Z / \partial W_1, W_2$	$< 10^{-15}$
LayerNorm Jacobian	8.3×10^{-8}
LayerNorm Hessian	1.5×10^{-7}
Transformer Jacobian	1.5×10^{-7}
Transformer Hessian [†]	1.6×10^{-7}

Блочная структура H_{tr}



Инициализированная модель



После обучения

Ключевые наблюдения

- ▶ Блоки **Values-Values** доминируют в обоих случаях
- ▶ Обучение усиливает гетерогенность (величины увеличиваются, структура сохраняется)
- ▶ Чисто FFN-блоки показывают меньшую кривизну (линейность ReLU)

Новизна: полная характеристика за пределами анализа только attention Ormaniec

Оценки спектральной нормы

Self-Attention (Теорема 1)

Для блоков по $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$:

$$\mathbf{H}^{(i,j)} = \mathbf{H}_o^{(i,j)} + \mathbf{H}_f^{(i,j)}, \quad \|\mathbf{H}^{(i,j)}\|_2 \leq C_o^{(i,j)} + C_f^{(i,j)}.$$

$$\|\mathbf{H}\|_2 \leq 3 \max_{i,j \in \{Q,K,V\}} \left(C_o^{(i,j)} + C_f^{(i,j)} \right)$$

	Q	K	V
Q	$\mathcal{O}(\ \mathbf{x}\ _2^6)$	$\mathcal{O}(\ \mathbf{x}\ _2^6)$	$\mathcal{O}(\ \mathbf{x}\ _2^5)$
K	.	$\mathcal{O}(\ \mathbf{x}\ _2^6)$	$\mathcal{O}(\ \mathbf{x}\ _2^5)$
V	.	.	$\mathcal{O}(\ \mathbf{x}\ _2^4)$

Оценки для полного трансформерного блока (Теорема 6)

$$\begin{aligned} \|\mathbf{H}_{\text{tr}}\|_2 \leq & 5 \max_{i,j} \left(\left\| \frac{\partial^2 \mathcal{L}}{\partial \mathbf{Z}^2} \right\|_2 \|\mathbf{J}_Z \mathbf{B}_i\|_2 \|\mathbf{J}_Z \mathbf{B}_j\|_2 + \right. \\ & \left. + \left\| \frac{\partial \mathcal{L}}{\partial \mathbf{Z}} \right\|_2 [\|\mathbf{J}_Z\|_2 \|\xi_{ij}\|_2 + \|\mathbf{B}_i\|_2 \|\mathbf{H}_Z\|_2 \|\mathbf{B}_j\|_2] \right). \end{aligned}$$

Что входит в оценку

- ▶ кривизна функции потерь;
- ▶ якобианы LayerNorm и FFN;
- ▶ вторые производные self-attention;
- ▶ попарные взаимодействия ξ_{ij} ;
- ▶ residual-пути через $\mathbf{J}_{SY}$.

Анализ сходимости ландшафта функции потерь

Постановка

- ▶ Эмпирическая функция потерь: $\mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k l_i(\mathbf{w})$
- ▶ Разложение Тейлора в общем минимуме $\mathbf{w}^*$ (предположение 1):

$$\mathcal{L}_k(\mathbf{w}) \approx \mathcal{L}_k(\mathbf{w}^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}^*)^\top \mathbf{H}^{(k)}(\mathbf{w}^*)(\mathbf{w} - \mathbf{w}^*)$$

Теорема 7 (сходимость)

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{2L}{k+1} + \frac{M\|\mathbf{w} - \mathbf{w}^*\|_2^2}{k+1}$$

где $L = \sup l_i$ и M из теоремы 3.4 или 3.6

Следствие: скорость убывания $\mathcal{O}(1/k)$ даёт практикам ориентиры по размеру выборки



Экспериментальная проверка

Постановка

- ▶ ViT на MNIST (1 блок, $d_V = 16$) и CIFAR-100 (8 блоков, $d_V = 128$)
- ▶ Обучение до $> 50\%$ точности на валидации
- ▶ Измерение блоков Гессиана через `curvlinops`

Наблюдение 1: блоки Values-Values демонстрируют наибольшие величины

Наблюдение 2: $|\mathcal{L}_{k+1} - \mathcal{L}_k|$ следует лог-линейному убыванию в лог-лог графике



Выводы и направления развития

Широкие применения

1. **Оптимизация второго порядка:** позволяет кривизно-осознанное предобуславливание (например, поблочные learning rate, масштабированные на $\|\mathbf{H}^{(i,j)}\|_2^{-1}$)
2. **Законы масштабирования:** механистическая связь между спектром Гессiana и компромиссами данные-модель (оптимальное по вычислениям обучение)
3. **Сложность по выборке:** практические рекомендации для областей с дефицитом данных (медицинская визуализация, научные открытия)

Заключение

Вклад: первая полная характеристика второго порядка блоков трансформера через явные матрицы Гессе LayerNorm/FFN

Значимость: связывает теорию (матричное исчисление) и практику (законы масштабирования, оптимизация)